Personalización

La personalización de Atlas se centrará en adaptar la presentación de las alertas a las necesidades de cada autoridad, sin modificar la información ni la valoración del riesgo. Por ejemplo, las autoridades sanitarias tendrán una presentación centrada en los riesgos para la salud pública, mientras que las portuarias y de seguridad podrán priorizar las anomalías de navegación. También se podrán ofrecer distintos niveles de detalle, desde un resumen hasta una vista completa de la alerta. En cualquier caso, todas las autoridades tendrán acceso a las mismas evidencias y a la información relevante, evitando que la personalización oculte datos o genere valoraciones contradictorias. Este planteamiento sigue los principios de transparencia y explicabilidad de la OCDE [1].

En cuanto a los criterios de detección, se mantendrán unos umbrales comunes para todos los puertos, establecidos y validados por Atlas. Aunque esto limita la adaptación a las necesidades locales, facilita la comparación de resultados y evita que las preferencias de cada autoridad alteren la detección. Los umbrales podrán revisarse a partir de evaluaciones periódicas, siempre que los cambios estén justificados y se validen antes de aplicarlos.

Por otra parte, se recogerán las valoraciones de los funcionarios sobre las alertas para identificar posibles errores y estudiar mejoras. Sin embargo, estas no modificarán automáticamente el modelo, ya que las decisiones humanas también pueden contener errores o sesgos. Además, una alerta descartada no implica necesariamente que la anomalía detectada sea falsa. Por ello, cualquier modificación se evaluará previamente mediante pruebas con datos verificados, comparando sus resultados con los de la versión anterior. Este procedimiento permitirá evaluar tanto las falsas alarmas como los riesgos que el sistema no haya detectado, siguiendo las recomendaciones del marco de gestión de riesgos del NIST [2].

Por último, la personalización tendrá límites para evitar que las preferencias de los usuarios condicionen las alertas. No se permitirá modificar los resultados para favorecer determinados intereses ni excluir información relevante por motivos ideológicos, políticos o discriminatorios. Asimismo, se tendrá en cuenta el riesgo de que las autoridades confíen excesivamente en las recomendaciones de Atlas. Para evitarlo, el sistema mostrará las evidencias y las incertidumbres asociadas a cada alerta, dejando la interpretación de los resultados y las decisiones finales en manos de las autoridades. Estos límites son coherentes con los principios de supervisión humana y gestión de riesgos de la OCDE y el NIST [1, 3].

Referencias

[1] Organización para la Cooperación y el Desarrollo Económicos (OCDE). (2024). OECD AI Principles. OECD Legal Instruments

[2] Autio, C., Schwartz, R., Dunietz, J., Jain, S., Stanley, M., Tabassi, E., Hall, P. y Roberts, K. (2024). *Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile* (NIST AI 600-1). National Institute of Standards and Technology. PDF

[3] National Institute of Standards and Technology (NIST). (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0) (NIST AI 100-1). PDF