Universidad Complutense de Madrid
Facultad de Informática
Grado en Ingeniería de Datos e Inteligencia artificial

Atlas

Sprint 3: Entrega Implicaciones Sociales de la IA

Ética de Datos e IA

Integrantes:
Filip Pablo Betanski Szubartowski
Vega García Camacho
Rosa Gómez-Gil Jónsdóttir
Daniel Higueras Llorente
Óscar Marín Esteban
Pablo Sánchez Lozano

Profesor: Samer Hassan
Curso académico: 2026/2027



En este sprint hemos realizado algunos cambios. En el sprint 2 dijimos que la responsabilidad recaí íntegramente en el gobierno contratante. Ahora la repartimos entre el proveedor de Atlas, la autoridad, el profesional que revisa la alerta, la unidad de reclamaciones, un revisor independiente y la auditoría externa. Es una propuesta de gobernanza, no una atribución jurídica. Aun así, Atlas sigue siendo una herramienta de apoyo: sus alertas no ordenan inspecciones.

A partir de las críticas y preguntas que surgieron durante el debate anterior, hemos podido identificar nuevas cuestiones que necesitábamos abordar y proponer medidas para mejorar el funcionamiento de Atlas.

En primer lugar, hemos elaborado una tabla con diez riesgos de diferentes tipos, valorando su gravedad y probabilidad en una escala del 1 al 4 para calcular su nivel de riesgo. Entre ellos, destaca la posibilidad de que Atlas sea considerado un sistema de alto riesgo según el Reglamento de IA, que ha obtenido la puntuación más elevada. También hemos incorporado problemas planteados durante el debate, como la posibilidad de que una falsa alarma desencadene una cadena de decisiones equivocadas. Este análisis nos ha permitido concretar mejor las posibles dificultades y sus consecuencias, como se recoge en el apéndice correspondiente.

Además, hemos definido un protocolo de actuación ante emergencias que contempla tres niveles de parada, responsables y suplentes, siete condiciones de activación y un procedimiento con plazos concretos. Entre las medidas propuestas, se establece el bloqueo del sistema en un máximo de 60 segundos y el envío de un aviso en 15 minutos. También hemos planteado un umbral provisional del 20 % de errores en 50 alertas para activar determinadas medidas, aunque será necesario validarlo durante una prueba piloto antes de considerarlo definitivo.

Otro de los aspectos que hemos desarrollado es la rendición de cuentas. Para ello, hemos diseñado un canal de reclamaciones accesible en español e inglés, que no requiere crear una cuenta ni utilizar un chatbot. Asimismo, hemos establecido unos plazos de respuesta y resolución, con un acuse de recibo en dos días hábiles, una atención prioritaria de los casos urgentes en cuatro horas y una resolución en un máximo de 15 días hábiles, ampliable a 30 cuando sea necesario. También hemos definido tres niveles de revisión humana y cinco posibles formas de reparación. Es importante señalar que estos plazos son compromisos propuestos por nuestro grupo y no deben confundirse con obligaciones legales.

Por otra parte, hemos profundizado en el análisis de los usuarios de Atlas, las personas afectadas por sus decisiones y las relaciones de poder que existen entre ellos. En relación con ello, hemos identificado seis tipos de sesgos, acompañados de ejemplos y medidas para reducirlos según su origen, ya sea en los datos, el modelo, el producto o el propio equipo de desarrollo.

Finalmente, hemos completado el análisis de la plausibilidad del sistema, sus partes más frágiles, las líneas rojas que delimitan nuestros principios, los colectivos vulnerables y la interseccionalidad, así como los compromisos de equidad y las métricas para evaluar su cumplimiento.