Emergencias: parada segura y recuperación de Atlas

Atlas debe poder detenerse cuando continuar utilizándolo pueda causar daños o cuando no sea posible garantizar la fiabilidad de sus resultados. La supervisión humana sólo será efectiva si las personas responsables tienen capacidad real para interrumpir el sistema, aunque hacerlo implique retrasar su actividad.

Este planteamiento se apoya en el marco de gestión de riesgos del NIST, que contempla asignar responsabilidades y establecer mecanismos para desactivar sistemas cuyo comportamiento sea incompatible con su uso previsto. También coincide con los principios de la OCDE sobre la posibilidad de intervenir, reparar o retirar un sistema de forma segura. [1, 2]

1. Qué significa parar Atlas

Una parada de Atlas interrumpe la generación o distribución de sus alertas y prioridades de revisión. No detiene automáticamente la actividad del puerto ni cancela las actuaciones de las autoridades, que mantienen sus competencias y pasan a trabajar mediante sus procedimientos habituales y fuentes verificadas.

Se establecen tres niveles de intervención:

Nivel	**Alcance**	**Ejemplo**
Retirada de una alerta	Se bloquea su utilización y se identifica como pendiente de revisión o invalidada	Una alerta asocia un aviso sanitario con un buque que no pasó por la zona afectada
Suspensión parcial	Se detiene una fuente, módulo o instalación concreta, manteniendo únicamente las funciones cuya independencia y seguridad puedan comprobarse.	Se suspende el análisis sanitario porque se ha incorporado un boletín manipulado.
Suspensión general	Se interrumpe la generación y distribución de alertas en todas las instalaciones afectadas	Una actualización introduce errores compartidos por varios puertos o compromete la integridad del sistema.

La intervención tendrá el alcance necesario para contener el problema. Si no se puede delimitar qué componentes están afectados, se suspenderá todo el ámbito potencialmente comprometido hasta aclararlo.

2. Quién puede ordenar la parada

Antes de poner Atlas en funcionamiento, cada instalación deberá identificar a los responsables y sus suplentes. No bastará con asignar la responsabilidad a un equipo de forma genérica.

Responsable	Capacidad de intervención
Operador autorizado de la autoridad usuaria	Puede retirar una alerta del circuito operativo y activar una suspensión preventiva de Atlas en su instalación cuando detecte un riesgo grave. No necesita autorización comercial ni esperar a que termine una investigación
Responsable de guardia de la autoridad	Coordina la continuidad del servicio mediante procedimientos manuales y determina qué decisiones anteriores necesitan revisión urgente.
Responsable técnico o de seguridad de Atlas	Puede aislar fuentes, detener módulos y suspender el servicio en varias instalaciones cuando el fallo sea compartido.
Controles automáticos de seguridad	Bloquean salidas o componentes cuando detectan condiciones objetivas previamente definidas. No autorizan el reinicio.
Auditoría y supervisión independiente	Puede activar una solicitud prioritaria de suspensión. Como compromiso de gobernanza, un hallazgo crítico documentado obliga al responsable de guardia a aplicar una suspensión preventiva mientras se verifica

Las personas afectadas también podrán comunicar emergencias mediante el canal de reclamaciones. No dispondrán de acceso directo al control de parada, pero sus avisos deberán recibir atención humana urgente cuando describan un daño grave en curso.

3. Cuándo se activa: condiciones medibles

Los siguientes criterios son compromisos iniciales de Atlas. Los controles técnicos se comprobarán antes de publicar cada alerta cuando sea posible; los indicadores de calidad se revisarán diariamente.

Situación	Condición de activación	Respuesta

Fallo de trazabilidad	Una alerta no puede vincularse a sus fuentes, fecha, versión del sistema o registro de generación.	Bloquear esa alerta. Si el fallo afecta al mecanismo general de registro, suspender nuevas publicaciones.
Evidencia falsa o manipulada	Se confirma al menos una alerta sustentada en un documento falsificado o en una afirmación relevante que no aparece en la fuente citada	Retirar la alerta, aislar el componente implicado y revisar todas las salidas que dependan de él.
Acceso o divulgación no autorizados	Se detecta una extracción de información restringida o una alteración no autorizada de datos, permisos o configuración.	Aislar el servicio afectado y suspender las funciones comprometidas.
Actuación fuera del alcance de Atlas	Se identifica una orden operativa emitida por una integración sin autorización humana, o una salida que presenta como hecho una acusación o diagnóstico que Atlas no puede establecer.	Bloquear la salida y suspender la función que permitió producirla o ejecutarla.
Criterio discriminatorio prohibido	Se verifica que una regla eleva la prioridad exclusivamente por nacionalidad, bandera o ausencia de datos, sin evidencia adicional pertinente.	Suspender esa regla y revisar las alertas que haya generado
Deterioro de la calidad	En las últimas 50 alertas con verificación independiente, más del 20 % contienen errores materiales de datos, atribución de fuentes o correspondencia geográfica o temporal.	Suspender el módulo implicado e investigar la causa. Es un umbral provisional que deberá validarse en el piloto
Pérdida de supervisión humana	No hay ningún operador autorizado disponible en el turno para revisar las alertas de la instalación.	Suspender su uso operativo y activar el procedimiento alternativo de la autoridad.

Un *error material* es aquel que puede modificar la interpretación de la alerta o su prioridad de revisión. Una alerta archivada por un funcionario no se considera automáticamente un error: puede describir correctamente una anomalía que finalmente no requiere intervención.

El umbral estadístico sirve para detectar deterioros acumulados. Un solo incidente grave puede justificar la parada general, aunque no se hayan revisado 50 alertas. Asimismo, una concentración de alertas en una ruta o colectivo debe investigarse, pero no demuestra por sí sola discriminación.

4. Procedimiento de emergencia

1. **Activar la suspensión:** El operador utiliza un control visible de «Suspender Atlas», indicando el alcance y el motivo. Existirá una vía alternativa mediante la consola administrativa o el responsable de guardia si la interfaz no responde. El objetivo técnico inicial será bloquear nuevas salidas del ámbito seleccionado en un máximo de 60 segundos.
2. **Comprobar la contención:** Se verifica que la generación, las colas de distribución y las integraciones afectadas han dejado de publicar resultados. Si la parada no se confirma, el responsable técnico aislará el servicio por la vía alternativa.
3. **Avisar a los responsables:** Se registra la hora, quién activó la parada y qué funciones están afectadas. El responsable técnico de Atlas y el responsable de guardia de la autoridad deberán recibir el aviso en un máximo de 15 minutos. Estos tiempos se cuentan desde la activación, no desde el origen del fallo.
4. **Preservar las evidencias:** Se conservan las fuentes utilizadas, las salidas, las versiones y los registros necesarios para investigar el incidente, con acceso restringido. La suspensión no debe borrar ni sobrescribir las pruebas.
5. **Mantener la actividad por medios alternativos:** La autoridad consulta fuentes oficiales directamente y aplica sus procedimientos de revisión manual. La interfaz muestra de forma inequívoca que Atlas está suspendido; las alertas antiguas no se presentan como información actualizada.
6. **Revisar los efectos anteriores:** Se identifican las alertas emitidas desde el último estado fiable y sus destinatarios. Las alertas comprometidas se marcan como invalidadas o pendientes de revisión y se comunica su retirada a quienes las recibieron. La autoridad reevalúa las actuaciones que pudieran haberse apoyado en ellas.

La comunicación y el seguimiento de incidentes forman parte del enfoque del NIST, que incluye respuesta, recuperación e información a los actores afectados. [1]

5. Condiciones para volver a operar

Atlas no se reactivará automáticamente por el mero transcurso del tiempo. Para autorizar la recuperación deberán cumplirse estas condiciones:

- La causa del incidente está identificada y corregida, o el componente causante permanece aislado.
- Se ha delimitado el alcance y se han comunicado las alertas comprometidas.
- Se han superado las pruebas que reproducen el fallo y las pruebas de las funciones relacionadas.

- Se han recuperado los controles de acceso, la trazabilidad y la supervisión humana.
- El responsable técnico de Atlas y el responsable de la autoridad autorizan y registran el reinicio.

Cuando el incidente implique discriminación sistemática, manipulación de registros o daños graves, se exigirá además una revisión independiente previa. Si no se cumplen las condiciones, el sistema permanecerá suspendido.

La recuperación comenzará con una fase de observación sin uso operativo de sus resultados. Su duración y los criterios de aceptación se fijarán según el incidente, antes de iniciar las pruebas. Las correcciones del modelo o de los umbrales se validarán expresamente; las decisiones de los funcionarios no provocarán un reentrenamiento automático.

Como compromiso preventivo, se realizará un simulacro trimestral y después de cambios importantes. Se comprobarán el tiempo de parada, la recepción de avisos, la continuidad manual y la capacidad de recuperar el servicio sin perder evidencias.

Referencias

[1] National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1. Apartados MANAGE 2.1, 2.4, 4.1 y 4.3: alternativas sin IA, desactivación, gestión de incidentes y comunicación.

[2] OCDE. (2024). *Recommendation of the Council on Artificial Intelligence*. OECD/LEGAL/0449, actualización de 2024. Principios 1.4 y 1.5: robustez, seguridad y rendición de cuentas.

Estas referencias fundamentan los principios del protocolo. Los niveles de parada, responsables concretos, plazos y umbrales son nuestras decisiones propuestas para Atlas específicamente.