Tabla de riesgos

Esta tabla recoge los riesgos de Atlas que vemos más importantes, de tipos distintos. A cada uno le damos una gravedad y una probabilidad del 1 al 4, y el nivel es la multiplicación de las dos, que es como el NIST define el riesgo [1]. La tabla va ordenada de mayor a menor nivel. Varios riesgos salen de las preguntas que nos hicieron en el debate del 21/10 [8].

Gravedad: 1, leve: retrasa un barco y se corrige en el día. 2, moderada: afecta a varios barcos o deja un coste que hay que compensar. 3, grave: afecta a personas (tripulaciones retenidas, datos de salud expuestos) o a un puerto entero. 4, crítica: afecta a varios puertos a la vez o a derechos fundamentales.

Probabilidad: 1, rara: tienen que fallar varias defensas a la vez. 2, posible. 3, probable: ya ha pasado en sistemas parecidos. 4, casi segura si no se hace nada.

Riesgo	Descripción	G × P = nivel	Prevención	Contingencia
1. Alto riesgo legal	El Reglamento de IA trata como de alto riesgo los sistemas que valoran el riesgo sanitario o de seguridad de quien entra en un país [5]. Nos lo preguntaron en el debate [8].	4 × 3 = 12	Diseñar desde el inicio con supervisión humana, registro de alertas y gestión de riesgos.	Parar el despliegue hasta cumplir; la autoridad sigue en manual (Protocolo de actuación).
2. Castigar al que avisa (social)	Si un país avisa de un brote, todos sus barcos quedan marcados, y la próxima vez puede callarse [2].	3 × 3 = 9	Marcar solo los barcos que pasaron por la zona del brote, no todo el país.	Retirar las alertas que sobren (Protocolo de actuación) y contarlo en la auditoría.

3. Firmar sin revisar (humano)	El funcionario acaba aceptando lo que dice Atlas sin comprobarlo, como se ha visto en medicina [4].	3 × 3 = 9	Mostrar siempre pruebas y huecos; formación y alertas de prueba.	Revisar las decisiones de ese periodo y reforzar la revisión (Rendición de cuentas).
4. Falsa alarma en cadena (técnico)	Un aviso mal situado marca barcos en todos los puertos a la vez. Nos lo preguntaron en el debate [8].	4 × 2 = 8	Marcar solo la zona exacta y que cada puerto revise antes de parar un barco.	Suspensión general y procedimiento manual (Protocolo de actuación); avisar a los puertos.
5. Aviso de brote falso (abuso)	Alguien publica un aviso falso con apariencia oficial para frenar los barcos de un país.	4 × 2 = 8	Solo cuentan los avisos que se pueden comprobar en la web de la fuente oficial.	Retirar esas alertas, aislar la fuente y avisar (Protocolo de actuación y rendición de cuentas).
6. Instrucciones escondidas (seguridad)	Un boletín lleva dentro una orden para Atlas. Es el primer riesgo de la lista de OWASP [3].	2 × 3 = 6	Tratar el texto de los documentos como contenido, nunca como órdenes.	Aislar la fuente y revisar las alertas que la usaron (Protocolo de actuación).
7. Fuga de datos (privacidad)	La declaración de sanidad incluye datos de salud de la tripulación [6][7].	3 × 2 = 6	Usar solo los datos necesarios, con acceso restringido y registrado.	Aislar el servicio y avisar a los afectados y a la autoridad de datos.

8. Caída (operativo)	Atlas o una de sus fuentes deja de funcionar.	2 × 3 = 6	Modo degradado que avisa de los datos que faltan (Sprint 1).	Procedimiento manual (Protocolo de actuación), sin mostrar alertas antiguas como actuales.
9. Alertar de más (negocio)	Atlas vive de parecer útil y puede lanzar más alertas de las necesarias.	2 × 2 = 4	Cobrar por alertas confirmadas, no por número, y publicar las falsas alarmas.	Auditoría externa; ajustar umbrales y compensar (Rendición de cuentas).
10. Aviso caducado (datos)	Atlas usa como vigente un aviso que ya no lo está.	2 × 2 = 4	Comprobar la vigencia; si no se puede, marcarlo como no verificado.	Retirar esas alertas y avisar a quien las recibió (Protocolo de actuación).

Hay dos riesgos más que no están en la tabla porque los trata el apéndice *Sesgos potenciales*: los huecos de datos de los puertos con menos medios y la discriminación por bandera.

Referencias

[1] National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1, apartado 1.1. https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-1.pdf

[2] Organización Mundial de la Salud. (30/11/2021). *WHO advice for international traffic in relation to the SARS-CoV-2 Omicron variant (B.1.1.529)*. https://www.who.int/news-room/articles-detail/who-advice-for-international-traffic-in-relation-to-the-sars-cov-2-omicron-variant

[3] OWASP. (2025). *LLM01:2025 Prompt Injection*. OWASP Top 10 for LLM Applications 2025. https://genai.owasp.org/llmrisk/llm01-prompt-injection/

[4] Goddard, K., Roudsari, A. y Wyatt, J. C. (2012). *Automation bias: a systematic review of frequency, effect mediators, and mitigators*. Journal of the American Medical Informatics Association, 19(1), 121-127. https://doi.org/10.1136/amiajnl-2011-000089

[5] Unión Europea. (2024). *Reglamento (UE) 2024/1689 de Inteligencia Artificial*, anexo III, punto 7.b. https://eur-lex.europa.eu/eli/reg/2024/1689/oj

[6] Unión Europea. (2016). *Reglamento (UE) 2016/679, General de Protección de Datos*, artículo 9. https://eur-lex.europa.eu/eli/reg/2016/679/oj

[7] Organización Mundial de la Salud. (2016). *Reglamento Sanitario Internacional (2005)*, 3.ª ed., anexo 8. https://www.who.int/publications/i/item/9789241580496

[8] Acta del 21/10/2026, debate 3 (Atlas), tomada por el grupo 6: preguntas de Claudia (alto riesgo) y de Lucía (paralización en cadena). https://docs.google.com/document/d/1zj2s56w4hRHQlNVolQ-uNYMSIvdKz3idUNyhVNQsNOs/edit

[9] Anthropic. (2026). *Claude*, conversación en Claude Code del 24/10/2026, sin enlace público. Claude propuso los riesgos a partir de los sprints 1 y 2 y del acta del debate, las probabilidades y la redacción de la tabla. Yo elegí los riesgos, puse las gravedades y revisé cada fila.