Sesgos potenciales y consecuencias prácticas

Origen del problema	Tipo de sesgo	Qué ocurre y ejemplos prácticos
Registros e inspecciones pasadas	Sesgo histórico	El modelo de Machine Learning hereda patrones discriminatorios del pasado. [1] *Ejemplo:* Repetir un escrutinio desproporcionado sobre determinados buques o navieras basándose únicamente en expedientes anteriores sesgados.
Datos AIS y registros marítimos	Sesgo de medición	Los datos de entrada (como las posiciones de los transpondedores AIS o los avisos) son incompletos o defectuosos. *Ejemplo:* Barcos que navegan con peor calidad de información técnica son evaluados con métricas imprecisas que generan incertidumbre.
Puertos y zonas con menor digitalización	Sesgo de infrarrepresentación	Zonas geográficas o puertos con peor infraestructura tecnológica o menor volumen de datos digitalizados tienen peor visibilidad en el sistema. [1] *Ejemplo:* Sus buques sufren valoraciones más deficientes o arbitrarias al estar peor representados en los datos globales.
Bandera o nacionalidad de la tripulación	Sesgo por variable sustituta (*proxy*) y estigmatización	El sistema utiliza características asociadas (como el país de origen de la bandera) que actúan de forma indirecta como discriminación. *Ejemplo:* Aunque no se busque discriminar, se estigmatiza a la tripulación (frecuentemente de países vulnerables), afectando injustamente su presunción de inocencia y sus

		derechos.
Rutas por zonas con avisos oficiales	Sesgo geográfico	Se penaliza automáticamente la región o ruta por la que transita el buque según las alertas (como las de la OMS). *Ejemplo:* Se asume un riesgo elevado basándose solo en el mapa, sin valorar lo que realmente ha ocurrido a bordo de la embarcación.
Falta de revisión en casos ocultos	Sesgo de retroalimentación (*feedback loop*)	El sistema solo aprende de los casos que él mismo marca y las autoridades revisan, ignorando lo que se le escapa. [2] *Ejemplo:* Nunca descubre los errores u ocultamientos que pasan desapercibidos en zonas menos vigiladas, generando falsas alarmas recurrentes que pueden alterar la actividad portuaria.

Fuentes de sesgo y medidas de prevención o reparación

Para evitar que estos sesgos comprometan la justicia y la fiabilidad del proyecto, se han identificado las principales fuentes de error en cada área del sistema y las medidas adoptadas para prevenirlos o repararlos: [1]

- En los datos:
    - *Fuente:* Los registros históricos de navegación (AIS), las bases de datos de salud pública y la disparidad en la infraestructura digital de los puertos.
    - *Prevención:* Cruzar estrictamente la información con fuentes oficiales fiables (como la OMS o el Maritime Single Window) y emplear arquitecturas que comuniquen abiertamente el grado de incertidumbre ante datos ausentes.
- En el modelo y los algoritmos:
    - *Fuente:* Los criterios de diseño matemático, como los umbrales de desvío espacial o temporal, los pesos asignados a las variables de riesgo y las reglas de decisión para detectar anomalías a partir de los datos AIS y de salud pública.
    - *Prevención:* Establecer por diseño que Atlas actúe únicamente como una herramienta de apoyo. El algoritmo no toma decisiones ejecutivas ni diagnostica por sí mismo; se apoya en una arquitectura RAG que detalla la

incertidumbre de los datos, obligando a que la interpretación final de los umbrales, pesos y alertas recaiga siempre sobre personas humanas (las autoridades competentes).

- En el producto y la interfaz:
    - *Fuente:* Las diferencias de criterio entre los distintos usuarios del sistema (por ejemplo, la prioridad de sanidad frente a la de seguridad o la autoridad portuaria).
    - *Prevención:* Generar alertas explicables mediante LLMs que detallen el motivo exacto del aviso, sus limitaciones y los datos faltantes. Además, para reparar la falta de confianza, Atlas se compromete a someterse a auditorías externas y a publicar públicamente sus tasas de falsas alarmas.
- En el equipo de desarrollo (de la empresa):
    - *Fuente:* La homogeneidad técnica de los ingenieros y programadores, que pueden diseñar los algoritmos desde una perspectiva puramente matemática o occidental, desconectados de la realidad operativa diaria de los puertos, las navieras y las tripulaciones internacionales.
    - *Prevención:* Crear equipos de desarrollo multidisciplinares (integrando expertos en derecho marítimo, sanidad y operadores portuarios) y someter el diseño del software a un control ético externo antes de su implantación

Referencias

[1] Tabassi, E. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.AI.100-1

[2] Ensign, D., Friedler, S. A., Neville, S., Scheidegger, C. y Venkatasubramanian, S. (2018). Runaway feedback loops in predictive policing. Proceedings of the 1st Conference on Fairness, Accountability and Transparency, PMLR 81, 160-171. https://proceedings.mlr.press/v81/ensign18a.html