Plan de entrenamiento de Atlas y derechos de autor

Proponemos entrenar el componente que analiza trayectorias marítimas únicamente con datos cuyo uso podamos justificar, y mantener separado el modelo de lenguaje que redacta explicaciones a partir de fuentes oficiales. El volumen de información crecerá mediante fuentes autorizadas y versiones trazables, sin recurrir a una descarga indiscriminada de textos de internet.

1. Qué componentes aprenderán de los datos

Componente	Uso de los datos y alcance del entrenamiento
Análisis de trayectorias	Entrenar un modelo de anomalías espacio-temporales con posiciones, tiempos, velocidad, rumbo y variables derivadas de trayectorias autorizadas. Una anomalía será una señal para revisar, no una prueba de delito o enfermedad
Consulta documental	Preparar un índice de documentos autorizados y recuperar los fragmentos pertinentes. Generar embeddings transforma la representación de esos fragmentos, no implica reajustar automáticamente los parámetros del modelo que los calcula
Explicaciones	Utilizar inicialmente un LLM preentrenado, con sus parámetros congelados, al que se proporcionen los hechos comprobados y los fragmentos recuperados. No entrenarlo desde cero ni ajustarlo con el conjunto de boletines o expedientes

La generación aumentada con recuperación, o RAG, combina un modelo con información recuperada de una memoria documental externa. Este enfoque permite actualizar el corpus sin incorporar cada aviso mediante un nuevo entrenamiento. La propuesta de Atlas usa esa separación, pero no asume que la investigación sobre RAG demuestre cumplimiento jurídico o ausencia de errores. [1]

Las alertas seguirán sujetas a revisión humana. Los resultados de inspecciones y las decisiones de funcionarios no se convertirán automáticamente en etiquetas de entrenamiento. Primero habrá que comprobar los hechos, los posibles sesgos y el permiso para reutilizarlos.

2. Criterios jurídicos para admitir una fuente

Distinguiremos entre derechos sobre un texto o imagen y derechos sobre la base que los reúne. Que una posición, fecha o velocidad sea un hecho no autoriza a copiar sistemáticamente la base de un proveedor: pueden existir derechos sobre la estructura de la colección o una protección de la inversión del fabricante. [2]

Para el entrenamiento priorizaremos datos propios, materiales con una licencia compatible y contratos que permitan expresamente el uso previsto. La atribución de la fuente se cumplirá cuando corresponda, pero no sustituirá el permiso necesario para copiar, transformar o redistribuir materiales.

3. Fuentes previstas y usos permitidos

La admisión se resolverá por conjunto y versión, no por el prestigio de la entidad que publica los datos. Consultar una fuente, indexarla, entrenar con ella y publicar sus contenidos se evaluarán por separado.

Fuente	Uso previsto	Condición para incorporarla
Datos sintéticos propios	Ensayar trayectorias, cruces con avisos, errores de posición y falta de cobertura	Crear el simulador y los escenarios sin copiar una base restringida. Conservar el origen y marcar los resultados como sintéticos; no usarlos como prueba de rendimiento real.
AIS histórico con licencia o convenio	Entrenar y validar el modelo de trayectorias	Exigir permiso para descarga masiva, conservación, transformación, entrenamiento, uso comercial si procede y acceso de proveedores. Acordar aparte la redistribución de datos y modelos.
MarineCadastre de NOAA y BOEM	Candidato para pruebas con AIS histórico en aguas de Estados Unidos	Revisar los metadatos y términos del lote y atribuir la fuente. La FAQ permite productos derivados y matiza el alcance territorial del dominio público. No damos por resuelta su reutilización en España. [5, 6]

Disposiciones legales oficiales	Corpus de consulta sobre obligaciones aplicables.	Utilizar textos oficiales. El art. 13 de la Ley de Propiedad Intelectual excluye determinadas normas y actos públicos de su protección; esa exclusión no se extiende sin más a comentarios, fotografías o ediciones de terceros. [2]
Avisos y publicaciones de la OMS	Consultar los avisos relevantes y, si el permiso lo permite, incorporarlos al índice RAG.	Comprobar la licencia de cada pieza. La política de la OMS incluye materiales CC BY-NC-SA 3.0 IGO y exige permiso para usos comerciales. No trasladar automáticamente un corpus académico a un servicio comercial. [7]
MSW DUEPORT y registros institucionales	Consulta operativa por usuarios autorizados	El acceso institucional no autoriza por sí solo entrenar. Se necesitaría un acuerdo específico y comprobar derechos de terceros, finalidad, confidencialidad y protección de datos. Sin ello, quedan fuera del entrenamiento. [8]
Datos y anotaciones del equipo	Documentar escenarios, correcciones y ejemplos de explicación	Documentar la aportación y el permiso de quien la realiza. No incluir expedientes de terceros, fragmentos copiados o textos generados cuyo origen no se pueda verificar.

Quedarán fuera de la primera versión artículos de prensa, informes comerciales, manuales de terceros, capturas de plataformas y repositorios sin una base de uso comprobada. Si una licencia limita el uso a fines no comerciales, no se considerará adecuada para la fase comercial sin autorización adicional. Quitar un nombre de un documento no elimina los derechos de autor ni garantiza su anonimato.

4. Minería de textos y datos y límites del plan

La Directiva (UE) 2019/790 distingue la minería para investigación científica de organismos habilitados, en su artículo 3, y la excepción general del artículo 4. Esta última exige acceso lícito y que los titulares no hayan reservado los derechos de forma adecuada. No equivale a un permiso general para reutilizar el contenido en cualquier producto. [3]

En España, el artículo 67 del Real Decreto-ley 24/2021 contempla reproducciones y extracciones para minería de textos y datos de obras accesibles legítimamente, con las condiciones previstas, incluida la reserva de derechos y la conservación vinculada a esa finalidad. [4]

Para Atlas, la vía ordinaria será la licencia o autorización documentada. Si se planteara utilizar una excepción legal, antes habría que verificar que cubre el sujeto, el contenido, el acceso y las operaciones concretas. [3, 4]

Registraremos las reservas de derechos y las condiciones de acceso que afecten a cada fuente. La ausencia de una indicación en robots.txt no se interpretará como una licencia para todos los usos. Tampoco eludiremos muros de pago, autenticación o controles técnicos para formar el corpus. Estas son reglas internas de adquisición; no pretenden resumir todas las formas posibles de reserva de derechos.

5. Procedimiento de entrenamiento a gran escala

5. 1. Alta de fuentes y trazabilidad

Antes de descargar un lote, la persona responsable de datos preparará una ficha de la fuente. Incluirá entidad publicadora y titular conocido, URL o identificador, versión y fecha de acceso, licencia exacta o contrato, prueba de autorización, reservas, usos admitidos, límites de conservación y condiciones de atribución. Separará los permisos de consulta, indexación, entrenamiento, envío a terceros y publicación. La ficha se completará con cobertura geográfica y temporal, variables, limitaciones y proceso de recogida. Seguimos la propuesta de documentar motivación, composición, recopilación y usos recomendados de los conjuntos de datos. [9]

5. 2. Descarga y preparación

La ingesta utilizará APIs autorizadas o descargas masivas ofrecidas por la fuente, respetando sus límites. Cada lote conservará un identificador y una huella digital para relacionarlo con sus permisos y detectar cambios. Los datos originales permanecerán separados del índice documental y de los conjuntos preparados para entrenamiento. Se eliminarán duplicados, registros corruptos y campos innecesarios; se documentará cada transformación. La base de entrenamiento de trayectorias excluirá nombres y datos de salud de tripulantes. Cuando sea necesario agrupar posiciones de un mismo buque, se empleará un identificador interno y se protegerá su correspondencia; la seudonimización no se presentará como anonimización. La licitud y la minimización de datos se revisarán además del copyright. [10]

5. 3. Preparación del aprendizaje y evaluación

El entrenamiento se organizará por periodos y zonas autorizados, procesados en lotes para poder ampliar el volumen sin perder la trazabilidad. Para cada ejecución guardaremos la versión de los datos, los filtros, las variables, la configuración y el modelo resultante. Un lote sin ficha o con un permiso incompatible no entrará en la ejecución, aunque haya pasado los controles de calidad.

La partición de entrenamiento, validación y prueba se hará por trayectorias completas y por tiempo. Se evitará que puntos de una misma trayectoria aparezcan a ambos lados de una partición. Se reservarán pruebas con buques o zonas no vistos cuando el objetivo sea medir generalización a ellos. Esto permitirá aprender patrones de memorizar trayectos concretos. Mediremos la precisión de las alertas y las falsas alarmas, separando resultados por tamaño de embarcación, zona y disponibilidad de datos. Un hueco AIS se registrará como incertidumbre; no se etiquetará automáticamente como conducta peligrosa. Las comprobaciones mantendrán los compromisos de equidad del Sprint 3, sin utilizar las decisiones de inspección como una verdad incuestionable. [2]

5. 4. Aprobación de cada nueva versión

Cada versión tendrá un informe con resultados técnicos y un registro de las fuentes efectivamente utilizadas. La ampliación del corpus exigirá revisar los permisos del nuevo lote; una aprobación antigua no se extenderá a contenidos nuevos o a otra finalidad. Si no hay datos autorizados suficientes, se limitará el alcance del piloto en lugar de completar el conjunto con fuentes dudosas.

6. Uso del LLM y del corpus documental

La selección del LLM y del modelo de embeddings se registrará en el inventario de componentes del proyecto. Revisaremos por separado la licencia de los pesos, el código de inferencia y las condiciones del servicio, si lo hubiera. Unas condiciones que permitan ejecutar los pesos no acreditan por sí solas los permisos sobre todo el corpus con el que se preentrenó el modelo. Solicitaremos al proveedor información sobre procedencia de los datos y política de copyright. Se dará preferencia a modelos con documentación suficiente para evaluar ese riesgo.

Si esa información fuera insuficiente para el uso previsto, el módulo de explicaciones se limitará a plantillas redactadas por el equipo y campos comprobados, mientras se busca una alternativa adecuada. No afirmaremos haber auditado un corpus al que no tenemos acceso.

En la primera versión no habrá ajuste fino del LLM ni del modelo de embeddings con documentos institucionales. Un ajuste posterior requeriría un conjunto específico de ejemplos con permisos comprobados y una aprobación independiente. Cambiar un aviso en el índice RAG no se contabilizará como reentrenar el LLM. El índice RAG también se someterá a control de derechos: descargar, guardar, fragmentar, representar e introducir documentos en el contexto del modelo son operaciones que deben revisarse. Que no se modifiquen sus parámetros no elimina esas cuestiones. Se usarán solo fragmentos necesarios y autorizados, con referencia a la fuente y con acceso restringido cuando proceda.

6. 1. Explicaciones y proveedores externos

Las explicaciones distinguirán hechos comprobados, inferencias y datos ausentes. No se convertirán en un servicio para obtener copias extensas de boletines o informes. Cuando se reproduzca o adapte contenido, se respetarán las condiciones de la fuente; se recurrirá a enlaces cuando el contenido no pueda incorporarse legítimamente. Eliminar palabras o resumir un texto no se considerará una solución automática a los derechos que lo protegen.

La investigación ha mostrado que ciertos modelos de lenguaje pueden revelar secuencias de sus datos de entrenamiento. Por eso probaremos peticiones de continuación literal, extracción de documentos y recuperación de información sensible. [11]

Las coincidencias detectadas se revisarán y podrán bloquear la publicación de la salida o del módulo afectado. Estas pruebas reducen riesgos, pero un resultado negativo no demuestra ausencia de infracción. Si se utiliza un servicio externo, el contrato y la configuración deberán impedir la reutilización de los datos de Atlas para entrenar modelos del proveedor, definir la retención y permitir su eliminación cuando corresponda. No se enviarán contenidos institucionales o de terceros si el acuerdo de origen no lo permite. La misma revisión se aplicará a logs, copias de seguridad y servicios de monitorización.

7. Publicación y respuesta a problemas de derechos

Mantendremos separados el repositorio de código, los datos originales, los documentos de consulta, los índices, las anotaciones y los pesos entrenados. Publicar código bajo una licencia de software libre no autoriza a publicar una base de datos o documentos de terceros. Podrán hacerse públicos el procedimiento, las fichas que no revelen información reservada, las métricas agregadas y ejemplos sintéticos. Antes de distribuir un conjunto transformado o un modelo comprobaremos los permisos aplicables al resultado. No asumiremos que toda licencia de los datos se transmite automáticamente a los pesos, ni que nunca puede afectarlos: dependerá del material, del uso y de las condiciones concretas. La decisión quedará coordinada con el apéndice de licencias del Sprint 4.

Ante una reclamación fundada o una duda relevante, se bloquearán nuevas ingestas de la fuente y se localizarán sus documentos, índices, lotes y modelos derivados. Se retirará el material afectado cuando proceda y se evaluará si basta con reconstruir el índice o si es necesario reentrenar. Eliminar una fila o un PDF no garantiza borrar su influencia de un modelo ya entrenado. La conservación de evidencias y las actuaciones dependerán de los permisos y obligaciones aplicables; no se asumirá que todas las licencias son revocables.

8. Responsables y condiciones para continuar

Proponemos que el proveedor técnico de Atlas mantenga el registro de fuentes y las versiones de entrenamiento, y que una persona distinta revise los permisos antes de aprobar cada versión. La autoridad deberá autorizar el acceso y los usos de sus datos dentro de sus competencias; su autorización no sustituirá los derechos que correspondan a otros titulares. Las incidencias podrán llegar por el canal de reclamaciones.

Una versión solo continuará si todos sus lotes tienen una base de uso documentada, se conocen las restricciones de publicación, el tratamiento de datos personales está justificado y los controles técnicos y de salidas han sido revisados. La fecha o el volumen previsto no justificarán saltarse esos requisitos. Si falla alguno, se conservará la última versión válida o se limitará el sistema al material que sí pueda utilizarse.

Referencias

[1] Lewis, P., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.

[2] España. Real Decreto Legislativo 1/1996, Ley de Propiedad Intelectual. Arts. 12 y 13 y título VIII del libro II, en particular art. 133.

[3] Unión Europea. Directiva (UE) 2019/790. Arts. 2 a 4.

[4] España. Real Decreto-ley 24/2021, art. 67.

[5] NOAA y BOEM. Frequently Asked Questions AIS Data and Tools.

[6] NOAA MarineCadastre. AIS Vessel Traffic.

[7] OMS. Copyright Licensing and Permissions.

[8] Unión Europea. Reglamento (UE) 2019/1239, arts. 10 y 12.

[9] Gebru, T., et al. (2021; prepublicación 2018). Datasheets for Datasets. Communications of the ACM.

[10] Unión Europea. Reglamento (UE) 2016/679, RGPD. Arts. 5, 6 y 9.

[11] Carlini, N., et al. (2021; prepublicación 2020). Extracting Training Data from Large Language Models. USENIX Security.