Especificación del proyecto tras el debate del 28/10

En el debate [1] salieron siete cuestiones. En dos tuvimos que reconocer una laguna: qué es exactamente una falsa alerta y cómo detectar los casos que Atlas no señala. Las demás ya estaban cubiertas en parte y se cierran con ajustes concretos. Algunas quedan resueltas por lo definido en el Sprint 4. Mantenemos la postura de fondo: Atlas es una herramienta de apoyo que no decide ni sustituye controles. También corregimos una frase de la presentación: Atlas no asume tareas del Gobierno, solo ordena y explica información para que la autoridad decida.

1. Qué es una falsa alerta. Que una alerta se archive no significa que fuera errónea y lo distinguíamos en Emergencias, pero no en las métricas. Desde ahora, falsa alerta es solo la que contiene un error material: dato falso, buque equivocado, aviso caducado o zona mal situada, y las alertas correctas que se archivan se publican aparte como tasa de archivo. La clasificación no la hace el funcionario que archivó, sino la verificación independiente de una muestra. Este criterio se aplica en la métrica de equidad 1, en la transparencia trimestral y en el apartado de comunidad del apéndice de Modelo de negocio.

2. Consecuencias si se incumplen los plazos. Que no sean “plazos legales” no los hace voluntarios. En el Sprint 4, el apéndice de Modelo de negocio ya establece que Atlas se presta con acuerdos de nivel de servicio (SLA), y los plazos de reclamación pasan a ser cláusulas de ese contrato. Si se incumple un plazo, el caso pasa al nivel de revisión siguiente. Si el retraso es culpa del proveedor, hay penalización económica. Los incumplimientos se publican cada trimestre. Si se repiten, el contrato se revisa y Atlas no se activa en instalaciones nuevas. Lo mismo vale para los plazos del apéndice de Respuesta a reclamaciones (takedown).

3. Dos autoridades interpretan la misma alerta de forma opuesta. No buscamos eliminar las discrepancias, porque cada autoridad tiene competencias distintas, lo que buscamos es que no nazcan de información distinta y que no pasen desapercibidas:

- Las reglas y umbrales son iguales en todos los puertos y públicos (Inventario de activos y titularidades, fila 3).
- Cada alerta tiene un núcleo común de hechos, fuentes e incertidumbre que la personalización no altera.
- Si una autoridad actúa y otra archiva por el mismo hecho, el sistema lo señala al responsable de guardia, y quien adopta la medida más restrictiva justifica sus evidencias.

4. La bandera en las líneas rojas. La redacción de la línea roja 3 dejaba la puerta abierta y la corregimos. La bandera y la nacionalidad nunca son variables del cálculo de prioridad. Solo sirven para identificar el buque y para auditar la equidad. Lo único que puntúa es que la ruta real haya pasado por una zona con un aviso oficial vigente. Eliminamos la referencia a “datos diplomáticos”, porque funcionaría como otra variable sustituta de la nacionalidad. Esta prohibición ya es vinculante para terceros: la licencia OpenRAIL-M del modelo prohíbe discriminar por bandera o nacionalidad (apéndice de Licencias).

5. Tiempo hasta detectar el fallo. Los 60 segundos cuentan desde la activación porque nadie puede prometer detectar un fallo al instante. Lo que sí garantizamos es cómo se detecta y qué se hace después:

- **Detección en tres capas:** controles de cada alerta antes de publicarla, alertas de prueba con respuesta conocida y el umbral del 20 %. A este umbral le añadimos una ventana máxima de 72 h, provisional hasta el piloto.
- **Margen antes de cualquier daño:** una alerta no detiene ningún buque sin revisión humana previa, así que el riesgo en ese intervalo está limitado.
- **Revisión retroactiva:** tras la parada se revisan todas las alertas emitidas desde el último estado fiable.

6. Evaluación a posteriori. Se establece un plan de evaluación en tres fases [3]:

- **Piloto** sin uso operativo, para validar todos los umbrales provisionales.
- **Métricas trimestrales.**
- **Evaluación externa anual**, que decide si Atlas sigue aportando valor frente al procedimiento manual.

7. Casos que Atlas no detecta. Es la laguna que reconocimos, y coincide con el sesgo de retroalimentación de nuestra propia tabla de sesgos [2]. No se pueden conocer todos los casos no detectados, pero sí estimarlos:

- **Cruce con otras vías:** se comprueba si Atlas había alertado en los casos detectados por inspecciones manuales y declaraciones de sanidad.
- **Muestra aleatoria:** se revisa una muestra de buques sin alerta, lo que además rompe el bucle de retroalimentación.
- **Publicación conjunta:** la precisión se publica siempre junto con la estimación de casos no detectados.
- **Nueva línea roja 5:** Atlas nunca reduce los controles existentes. Así, lo que se le escape sigue pasando por el procedimiento habitual.

8. Cuestiones pendientes del debate anterior y otros ajustes. En el debate del 21/10 dos cuestiones quedaron respondidas solo en parte, y las cerramos en este sprint. Además, al revisar los documentos hemos corregido dos incoherencias:

- **Métrica por tamaño de buque.** El Plan de entrenamiento (apartado 5.3) separa los resultados por tamaño de embarcación, zona y disponibilidad de datos.
- **Independencia de los auditores.** El auditor lo elige el gobierno y no puede tener otros contratos con Atlas. Además, el código AGPL permite auditar el sistema sin depender del proveedor.
- **Modelo de cobro.** El riesgo 9 del Sprint 3 proponía cobrar por alertas confirmadas. Lo sustituimos por el modelo del apéndice de Modelo de negocio, que cobra por recursos, mantenimiento e integración y no por alertas.
- **A quién informa Atlas.** Atlas informa solo a las autoridades; es la autoridad quien informa al afectado cuando actúa (especificación del Sprint 3, punto 6). Corregimos el apartado de plausibilidad del Sprint 3, que decía lo contrario.

Referencias

[1] Acta del 28/10/2026, debate del Sprint 3 (Atlas), [EIA - Actas 2026-27]
[2] Ensign, D., Friedler, S. A., Neville, S., Scheidegger, C. y Venkatasubramanian, S. (2018). Runaway feedback loops in predictive policing. PMLR 81, 160-171. https://proceedings.mlr.press/v81/ensign18a.html
[3] National Institute of Standards and Technology. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1, apartados MEASURE 2 y MANAGE 4. https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-1.pdf